

ProjectName – C/Java/Python

Rapport final

AIT-ISSAD MOHAMED SAID, BILAL AL FAYOUMI, AMARA KOUSSAY, GUILLEM CAUSS

9 avril 2026

Introduction

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.

Pellentesque iaculis molestie euismod. In hac habitasse platea dictumst. Duis eu gravida sem. Vivamus pulvinar, tellus auctor sollicitudin iaculis, quam massa blandit ligula, in mollis est tellus et velit. Nulla gravida sapien nibh, nec faucibus lorem aliquam sed. Curabitur rutrum elit purus, et congue neque venenatis vitae. Sed non magna nisi. Pellentesque euismod non ipsum a hendrerit. Pellentesque vehicula tincidunt lacinia. Sed rhoncus porttitor facilisis.

Etiam sed molestie odio. Nunc cursus sollicitudin est vitae posuere. Nullam pellentesque metus eu dui porttitor bibendum. Morbi egestas arcu ut urna dictum placerat non non nisl. Quisque non ante in eros cursus pulvinar. Sed augue libero, eleifend a urna eget, pellentesque condimentum odio. Sed sed dui non diam mattis interdum eget sed urna. Integer consectetur, erat id rutrum posuere, dui velit dictum mi, quis tincidunt magna diam sit amet nunc. Etiam dui augue, sollicitudin rhoncus nisl a, rhoncus tempor purus.

Suspendisse cursus erat et metus fermentum ullamcorper. Etiam eros arcu, dapibus quis efficitur ut, congue id nunc. Pellentesque aliquam venenatis convallis. Nulla nisi justo, aliquet quis lacus eget, aliquet maximus velit. Maecenas ex turpis, iaculis eget dignissim non, efficitur vel mi. Maecenas pharetra elit ornare sem suscipit ornare id id sapien. Vivamus sem neque, consectetur vitae aliquet non, finibus eu lectus. Fusce aliquam ipsum ut viverra vehicula. Donec ultrices varius nulla vel finibus. Donec convallis fringilla ante id porta.

1 Modélisation du jeu

1.1 Représentation de l'état du jeu

L'état d'une partie est centralisé dans `GameState`. La classe regroupe les positions des joueurs, les murs restants et posés, le graphe de connectivité et le joueur courant. Cette séparation entre état dynamique, contraintes de déplacement et progression du tour évite de disperser la logique métier.

Les positions utilisent un encodage linéaire :

$$node = row \times size + col.$$

Ce format simplifie l'accès aux structures indexées et les parcours. Les champs utilisés en exécution sont `board_size`, `current_player`, `player_positions`, `remaining_walls`, `vertical_walls`, `horizontal_walls` et `graph`. Cette représentation sert directement la validation des coups, l'historisation et la persistance.

1.2 Graphe du plateau et structures associées

Le plateau est modélisé par un graphe non orienté $G = (V, E)$: les sommets représentent les cases et les arêtes les déplacements élémentaires autorisés, conformément à `[?, ?]`. Le graphe est stocké en liste d'adjacence `dict[int, list[int]]`, adaptée à une grille creuse (degré maximal 4) avec un coût mémoire en $O(V + E)$.

Les murs sont appliqués comme suppressions d'arêtes plutôt que comme transformations géométriques `[?]`. La vérification de connectivité repose sur BFS, avec une complexité $O(V + E)$ sur graphe non pondéré `[?]`. Les distances de plus court chemin sont aussi réutilisées par les heuristiques IA, notamment pour Minimax et MCTS `[?, ?]`.

En complément, le moteur maintient `player_positions`, deux collections de murs (vertical/horizontal) et un historique de snapshots pour *undo/redo*.

1.3 Déplacements des pions et validation des murs

Les déplacements de base sont obtenus à partir des voisins du sommet courant dans le graphe. Lorsqu'un pion adverse occupe un sommet adjacent, la règle de saut s'applique si la case située derrière reste accessible ; sinon, des déplacements diagonaux sont autorisés selon les arêtes effectivement présentes. Ces cas dépendent de l'état courant des pions et sont traités dynamiquement dans `pawn_rules.py`.

La validation d'un mur combine deux contrôles : validité locale de placement (position, orientation, absence de chevauchement) et maintien d'un chemin vers la zone cible pour chaque joueur. L'implémentation effectue une suppression temporaire des arêtes concernées, exécute un BFS par joueur, puis valide la pose ou restaure l'état précédent. Sur une grille 9×9 , ce coût reste faible.

Le modèle retenu établit un lien direct entre structures de données et règles d'exécution : le graphe représente la connectivité, les règles dynamiques gèrent les cas contextuels et les vérifications globales assurent la validité de la partie.

2 Architecture logicielle

2.1 Architecture générale

Les Figures 1 et 2 présentent les composants principaux du projet en deux vues lisibles.




FIGURE 1 – Vue UML du noyau métier et de la couche applicative

L'architecture est organisée en couches : les modules d'interface et de réseau passent par la couche applicative, qui orchestre les opérations métier. **GameState** porte l'état, **GameSession** applique les transitions et **GameApplicationService** constitue le point d'entrée commun pour CLI, GUI, IA, persistance et réseau.

2.2 Modules et dépendances

Le module **core** contient le modèle métier (état, plateau, notation, snapshots). Le module **rules** implémente les validations de déplacements, de murs et de victoire. Le module **application** orchestre les cas d'usage et le cycle de partie. Les modules **interfaces** et **network** gèrent l'entrée/sortie utilisateur et les échanges client/serveur. Le module **utils** regroupe les composants techniques réutilisables (graphe, utilitaires), et **m1** porte les composants d'aide aux moteurs de recherche.

Les dépendances restent dirigées : **interfaces** → **application** → (**core**, **rules**, **utils**), avec **network** connecté à **application**. Cette orientation limite les cycles et isole le coeur métier.

```
quoridor/
|-- core/
|-- rules/
|-- application/
|-- interfaces/
|-- network/
'-- m1/
```




FIGURE 2 – Vue UML des interfaces, du réseau et des composants IA

2.3 Cheminement des actions

Toutes les actions passent par le même pipeline applicatif. Pour un déplacement utilisateur : interface → **GameApplicationService** → validation **rules** → mise à jour **GameSession/GameState** → historisation via **HistoryManager** → retour interface.

La pose de mur suit la même chaîne, avec simulation sur graphe et test BFS avant validation. Un coup IA suit également ce pipeline : **GameApplicationService** déclenche Minimax/MCTS, puis applique le coup sélectionné via les mêmes étapes de validation et de mise à jour.

2.4 Intégration des algorithmes

BFS est implémenté dans **rules/utils** pour les tests de connectivité. Les moteurs Minimax, alpha-bêta et MCTS sont orchestrés par **application**. Le mécanisme *undo/redo* repose sur **HistoryManager** et les snapshots d'état. La persistance et le parsing assurent la conversion entre formats externes et représentation interne, sans dupliquer la logique métier.

2.5 Design patterns utilisés

Command Dans le shell CLI, les commandes et **CommandRegistry** encapsulent les actions utilisateur et délèguent leur exécution à **GameApplicationService**. Cette structure découple saisie et exécution.

Strategy **PlayCommandStrategy**, **LocalPlayCommandStrategy** et **NetworkPlayCommandStrategy** isolent les variantes d'exécution local/réseau, sans multiplier les conditions dans la couche applicative.

Memento **GameSnapshot**, **MoveRecord** et **HistoryManager** conservent les états avant/après action, ce qui permet des restaurations cohérentes pour *undo/redo*.

Facade **GameApplicationService** joue le rôle de façade : il expose une API unique pour jouer un coup, poser un mur, gérer l'historique, piloter l'IA et charger/sauvegarder une partie.

Observer **EventBus** implémente un mécanisme d'observation léger entre producteurs et consommateurs d'événements, utile pour propager les mises à jour sans dépendances directes fortes.

L'ensemble produit une architecture compacte : responsabilités localisées, dépendances orientées vers le métier, et extensions (IA, réseau, interfaces) ajoutées sans modifier le noyau de règles.

3 Intelligence artificielle

3.1 Minimax avec élagage Alpha-Beta

Le Minimax explore récursivement l'arbre de jeu. À chaque nœud, il génère les coups légaux, applique chaque coup sur une copie de l'état, puis évalue les positions obtenues. Une victoire pour l'IA vaut +1 000 000, une défaite -1 000 000. À profondeur nulle, l'évaluation repose sur l'une des trois heuristiques configurables.

Sans élagage, le coût est exponentiel en fonction du facteur de branchement b et de la profondeur d : $O(b^d)$. Au Quoridor, ce facteur est élevé car il faut considérer à la fois les déplacements de pion et les poses de murs. L'élagage alpha-beta réduit ce coût en supprimant les branches qui ne peuvent plus influencer le résultat. La figure 3 montre ce cas simple : si MAX possède déjà une branche à 5, une branche adverse qui descend à 2 est coupée.




FIGURE 3 – Élagage alpha-beta : la branche droite est coupée car MIN a trouvé 2 alors que MAX dispose déjà d'une branche à 5.

Dans les modes à temps borné, la recherche vérifie une deadline avant chaque expansion de nœud. Si le temps est écoulé, elle s'arrête et renvoie le meilleur coup déjà calculé. Le pseudo-code correspondant est donné en figure 4.

```

fonction minimax(etat, profondeur, alpha, beta, maximise):
    verifier la deadline
    si etat terminal: retourner score final
    si profondeur = 0: retourner heuristique(etat)

    pour chaque coup legal:
        evaluer recursivement l'etat enfant
        mettre a jour la meilleure valeur courante
        mettre a jour alpha ou beta
        si beta <= alpha: arreter l'exploration

    retourner la meilleure valeur

```

FIGURE 4 – Pseudo-code du Minimax avec élagage alpha-beta

3.2 Iterative Deepening

Le problème d'un Minimax à profondeur fixe est simple : on ne sait pas à l'avance quelle profondeur sera atteignable dans le temps imparti. Au Quoridor, le coût varie fortement selon le nombre de murs encore disponibles.

L'Iterative Deepening lance donc plusieurs recherches successives à profondeur croissante : 1, puis 2, puis 3, etc. Quand la deadline est atteinte, on conserve le meilleur coup de la dernière profondeur complètement terminée. Ce choix garantit qu'un coup valide est toujours disponible, même sous une contrainte de temps stricte.

L'IA expose deux usages :

- **Profondeur explicite** (`-ai-minimax-depth`) : Minimax à profondeur fixe.
- **Temps limité** (`-ai-time`) : recherche itérative qui approfondit tant que le temps reste disponible.

Quand l'utilisateur choisit `minimax` sans préciser de profondeur, le programme convertit automatiquement le temps disponible en profondeur maximale selon les seuils du tableau ci-dessous.

Temps	Profondeur
≤ 1 s	1
≤ 3 s	2
≤ 6 s	3
≤ 12 s	4
> 12 s	5

3.3 Heuristiques

Nos algorithmes MiniMax appellent tous une fonction `evaluate_state()` qui prend en argument l'état du jeu, un id de joueur et le mode de l'IA. Nous en avons implémenté 3, 3 heuristiques basées sur différentes stratégies adaptées

```

fonction iterative_deepening(etat, joueur_ia, temps_max, prof_max):
    fixer une deadline
    initialiser meilleur_coup avec un coup legal

    pour profondeur croissante:
        lancer minimax a cette profondeur
        si la profondeur est entierement terminee:
            memoriser le meilleur coup
        sinon:
            arreter

    retourner meilleur_coup

```

FIGURE 5 – Pseudo-code de l'Iterative Deepening

au jeu du quoridor. La première est celle utilisée par défaut. Elle se concentre sur une comparaison directe entre le joueur et ses adversaires. Elle compare d'abord les distances entre l'IA et son objectif et de ses adversaires avec les leurs à partir de la fonction `get_shortest_path_length`, un algorithme de parcours en largeur (BFS) qui retourne le nombre de mouvements du chemin le plus court vers l'objectif du joueur. Si la distance de l'IA est plus faible, alors le score est positif. Elle prend également en compte le matériel en comparant son nombre de murs restants à celui de la moyenne des adversaires. Le poids accordé à la comparaison des murs est assez faible (on multiplie l'écart du nombre de murs restants par 0,5 si c'est une partie à 2 joueurs, 0,3 sinon), ce qui poussera l'IA à bouger son pion plutôt que de placer des murs.

La deuxième est basée sur le matériel, elle est plus agressive. Le poids des murs est plus élevé (x2 si 2 joueurs, 1,2 sinon) et la comparaison ne se fait pas avec la moyenne des murs restants adversaire cette fois-ci mais avec celui qui a le plus de mur uniquement. Cette différence est importante car l'IA se compare avec l'adversaire ayant le plus de murs. Ce choix permet à l'IA d'avoir une meilleure gestion de ses murs, en cas de partie où 2 adversaires n'ont plus de murs et un autre les a toujours tous, elle restera sur ses gardes plutôt que de dépenser tous ses murs car la moyenne des murs restants est basse. Également dans cette évaluation, on calcule la distance de l'adversaire le plus proche et on le multiplie par 2, l'IA va donc chercher à faire faire des détours à ses adversaires, quitte à rallonger son chemin au passage, tant qu'elle garde l'avantage du nombre de murs. Cette stratégie se concentre sur l'obstruction des adversaires, elle joue la montre, elle mise sur la victoire à long terme après l'épuisement des murs. C'est une stratégie très commune au Quoridor.

Enfin la troisième, la plus complexe, on peut l'imaginer comme une version hybride améliorée des deux premières. Elle mélange le positionnement spatial ainsi qu'une gestion dynamique des ressources. On introduit ici une composante de centralité, au quoridor, être au centre permet de plus facilement varier entre la gauche et la droite lorsqu'un adversaire pose un mur, c'est donc un avantage. Pour calculer ce bonus, on calcule la distance de Manhattan entre le pion du joueur et l'intersection entre la colonne centrale et la ligne centrale. Le poids de ce bonus est assez faible pour influencer l'IA entre 2 mouvements égaux à choisir celui qui se rapproche du centre, sans pour autant faire reculer son pion pour rester au centre, réduire la distance vers l'arrivée reste plus important. On a ensuite implémenté un poids dynamique des murs, si l'IA a plus de 2 murs, elle leur donne une faible importance (poids de 0,4). A partir de 2 murs et moins, le poids devient 0,8, elle devient plus conservatrice et préfère les conserver pour bloquer plus efficacement l'adversaire. De plus, on augmente encore plus le poids de la distance adversaire par rapport à la sienne ce qui rend l'IA plus agressive. Pour ces trois heuristiques, le calcul du chemin le plus court est coûteux mais précis, c'est donc un compromis intéressant.

Ces 3 fonctions d'évaluation sont appelées par une fonction parente, `evaluate_state`, qui est appelée par l'algorithme minimax et qui, en fonction de la valeur de l'attribut `scoring`, calcule la position avec l'heuristique choisi.

Critère	Standard (H1)	Matérielle (H2)	Hybride (H3)
Focus Principal	Vitesse relative	Obstruction	Positionnement
Référence Murs	Moyenne adverse	Max adverse	Seuil dynamique
Poids des Murs	0,3 - 0,5	1,2 - 2,0	0,4 → 0,8
Calcul Distance	BFS (Précis)	BFS (Pondéré ×2)	BFS (Agressif)
Bonus Spécial	Aucun	Aucun	Centralité (Manhattan)

TABLE 1 – Comparaison technique des trois heuristiques implémentées.

3.4 Monte Carlo Tree Search (MCTS)

3.4.1 Introduction

Alors que l'algorithme Minimax repose sur une exploration exhaustive et déterministe à profondeur fixe, le Monte Carlo Tree Search propose une approche stochastique basée sur l'échantillonnage de l'espace des états. Dans le cadre du jeu Quoridor, le passage au MCTS est motivé par deux caractéristiques majeures du jeu :

1- L'explosion du facteur de branchement : Avec la possibilité de déplacer un pion ou de placer un mur parmi la multitude de coordonnées et orientations, le nombre de coups légaux par tour est élevé. Une exploration complète devient rapidement impossible à mesure que la complexité combinatoire augmente.

2- La difficulté d'évaluation : Contrairement aux échecs, une position dite "avantageuse" au Quoridor est difficile à quantifier par une simple heuristique positionnelle et matérielle. En effet un simple mur bien placé peut totalement inverser la distance des joueurs vers leur objectif.

Le MCTS offre une solution : il accumule des simulations pour construire statistiquement une estimation de la valeur d'un coup. En pratique, le MCTS ne cherche pas à calculer l'arbre complet du jeu, ce qui serait impossible. A chaque tour, l'algorithme lance un cycle de simulations intensives qui s'exécute de manière itérative jusqu'à l'épuisement du temps imparti (défini par l'argument `-ai-time`).

L'algorithme construit progressivement un arbre partiel en mémoire. Chaque nœud de cet arbre représente un état du plateau et stocke deux statistiques cruciales issues des simulations passées :

- **Le nombre de visites (N)** : Combien de fois un état a été exploré.
- **Le nombre de victoires (W)** : Le succès cumulé des joueurs à partir de ce nœud.

Plus une branche semble prometteuse, plus l'algorithme y consacre de simulations. A l'inverse, les branches menant à des défaites rapides sont délaissées. Une fois le temps écoulé, l'IA ne choisit pas nécessairement le nœud ayant le meilleur ratio de victoire, mais le nœud ayant le plus grand nombre de visites. Ce critère est le plus robuste car il désigne le coup que l'algorithme a jugé le plus digne d'intérêt après des milliers de tests.

Un cycle de simulation est divisé en 4 phases :

1. **Sélection** : En partant de la racine (l'état actuel du jeu), l'algorithme descend dans l'arbre en choisissant à chaque niveau le nœud de l'enfant le plus pertinent. Ce choix repose sur la formule UCT, cette formule permet d'équilibrer l'exploitation des coups connus comme gagnants et l'exploration de coups encore peu visités :

$$UCT = \frac{W_i}{N_i} + C \times \sqrt{\frac{\ln(N_{parent})}{N_i}}$$

Où W_i est le nombre de victoires du nœud, N_i son nombre de visites et C une constante (souvent fixée à $\sqrt{2}$, c'est le choix approximatif que nous avons fait dans notre moteur, plus précisément 1,41). Ce jonglage se fait car le premier terme (exploitation) augmente avec le taux de victoire, tandis que le second (exploration) augmente si le nœud est délaissé par rapport à ses frères.

2. **Expansion** : Lorsqu'un nœud est atteint mais qu'il possède encore des coups non explorés (`untried_moves`), l'algorithme crée un nouveau nœud enfant pour l'un de ces coups et l'ajoute à l'arbre.
3. **Simulation (Rollout)** : Phase de plongée. A partir du nouveau nœud, l'IA simule une partie rapide jusqu'à la victoire d'un joueur. Cette simulation est habituellement aléatoire, afin de donner une idée rapide de si la position est gagnante ou non pour le joueur. Nous détaillons plus loin un choix technique concernant cette simulation afin d'améliorer notre moteur.
4. **Rétropropagation** : Une fois le vainqueur de la simulation connu, l'algorithme remonte de nœud en nœud jusqu'à la racine pour mettre à jour les statistiques (N et W) de tous les parents traversés lors de cette itération.

Ces quatre étapes forment le cycle de base d'un algorithme MCTS, dont l'efficacité repose théoriquement sur la convergence statistique vers les meilleurs coups au fil des simulations. Ce modèle est robuste pour des jeux à faible complexité mais présente de réelles limites lorsqu'on s'attaque à des jeux plus vastes comme le Quoridor.

3.4.2 Problématique

En effet, l'application d'un MCTS "pur", donc totalement aléatoire dans la simulation des coups, au Quoridor s'est avérée très instable lors de nos premiers tests. En effet, le facteur de branchement est tellement grand que simuler des coups aléatoires jusqu'à la victoire de l'un des joueurs à chaque nœud va créer un arbre beaucoup trop large et l'algorithme n'a pas le temps d'explorer suffisamment pour trouver un coup intéressant en seulement quelques secondes. Les simulations produisent un "bruit" important car les pions tendent à errer sans but et à placer des murs inutiles, ce qui rend les statistiques de victoire peu fiables pour l'algorithme.

Prenons pour exemple une partie à 2 joueurs sur un plateau de 9x9 cases. dès le premier coup, il y a 3 mouvements de pions possibles (avancer, droite, gauche) et 128 murs possibles (8 murs différents par ligne / colonne, donc 64

par orientations), on a un total de 131 coups légaux différents. Au mieux, les coups suivants auront minimum 124 possibilités et ainsi de suite, l'arbre devient très vite trop large et sa complexité augmente trop vite. Un algorithme explorant cet arbre de manière aléatoire va très vite se perdre.

Pour pallier ces limites, notre implémentation s'écarte du modèle classique en introduisant un élagage sélectif des coups, plus particulièrement sur le placement des murs, ainsi que des simulations guidées par des heuristiques de distance. Cette approche permet de concentrer la puissance de calcul sur les séquences de jeu les plus crédibles, réduisant ainsi drastiquement la largeur de l'arbre au profit de sa profondeur.

3.4.3 Optimisation de l'espace de recherche / Architecture et fonctionnement

L'efficacité de notre moteur MCTS (dans le fichier `mcts_engine.py`) repose sur une rupture avec l'approche "brute" classique. Au lieu d'explorer l'intégralité des coups légaux, l'algorithme se concentre sur un sous-ensemble de mouvements qualitatifs, réduisant ainsi le facteur de branchement de manière drastique.

Élagage stratégique des coups La fonction `get_tree_moves` est le premier filtre de l'algorithme. Dans une partie de Quoridor, nous avons vu que le nombre de murs posables est immense alors que la majorité n'ont aucun impact stratégique immédiat. A la place donc de créer un noeud représentant un état du jeu avec une liste de tous les coups possible depuis cet état, nous filtrons cette liste en nous basant sur 3 points importants :

- **Priorité aux déplacements** : L'algorithme inclut systématiquement tous les déplacements de pions légaux.
- **Ciblage des murs** : Nous utilisons la fonction `get_blocking_walls`, une heuristique de filtrage qui va tester à l'aide d'un algorithme BFS tous les murs et ne garder seulement les murs dits "bloquants". Un mur est considéré comme tel s'il augmente la distance du chemin le plus court de l'adversaire vers sa ligne d'arrivée. Nous effectuons un `clone_state(state)` à chaque itération, c'est l'opération la plus lourde de cette fonction mais l'efficacité du filtrage justifie ce coût de clonage répété.
- **Activation tardive** : L'exploration intensive des murs n'est activée que lorsque l'adversaire est à une distance inférieure à 5 de son objectif (on calcul ici la distance axiale, sans prendre en compte les murs, de la ligne / colonne du joueur jusqu'à sa ligne / colonne d'arrivée). Cela permet à l'IA de se concentrer sur sa propre progression en début de partie tout en devenant extrêmement défensive par la suite.

Il est important de préciser que lorsque la fonction `get_blocking_walls` retourne la liste des murs bloquant, la fonction `get_tree_move` n'en sélectionne que 3 au hasard. L'objectif ici est d'éviter l'explosion combinatoire, en effet même en ne gardant que les murs bloquants, il peut y en avoir une dizaine à chaque coups et le problème n'aurait été que déplacé. En ne prenant que 3 murs, nous faisons le pari statistique que parmi ces 3, au moins un sera suffisamment pertinent pour contrer l'adversaire. Étant donné que le MCTS est lancé plusieurs fois, l'aléatoire permet de tester des murs différents d'une partie à l'autre, finissant par identifier ceux qui mènent à la victoire sans que les options de murs ne saturent totalement le temps de calcul.

Simulations guidées par heuristiques Le point critique d'un MCTS est la phase de Simulation. Si les deux joueurs jouent n'importe comment, le résultat de la simulation ne reflète pas la qualité réelle du coup initial. Pour résoudre ce problème, nous avons implémenté une politique de simulation guidée.

- **Biais de progression** : Lors d'un rollout, le joueur n'est pas aléatoire. Il y a une forte probabilité (85%) qu'il choisisse un coup réduisant sa distance vers l'objectif (calculé par `get_shortest_path_length`). En forçant ainsi les pions à se diriger vers leur but, les simulations se terminent plus rapidement et imitent un comportement humain. Les statistiques de victoire (win / visits) deviennent alors un indicateur fiable de la solidité d'une position.
- **Gestion des murs en simulation** : Les rollouts ne posent jamais de murs, ils simulent uniquement la fin de partie avec les pions. Cela fait gagner en rapidité de calcul durant les simulations mais poussera l'IA à beaucoup consommer ses murs car elle voit l'avantage immédiat d'un mur posé dans l'arbre, mais elle ne va pas simuler le fait que l'adversaire pourrait répondre par un autre mur.
- **Compromis qualité/quantité** : Nous avons conscience qu'utiliser un algorithme de parcours en largeur pour calculer la distance la plus courte à chaque rollout est coûteux, mais ce coût est largement compensé par la pertinence des résultats obtenus. Nous choisissons en quelque sorte la qualité à la quantité, nous perdons en vitesse brute mais gagnons en précision.
- **Robustesse** : Nous avons fait le choix de garder 15% d'aléatoire ici afin de préserver la nature explorative du MCTS. Un rollout purement dirigé par le plus court chemin rendrait l'évaluation trop rigide et incapable d'anticiper les comportements humains de l'adversaire. Ce mélange permet d'obtenir des simulations qui sont à la fois efficaces et diversifiées.

Ainsi, nous avons conçu un MCTS capable de rivaliser avec un Minimax. Là où un MCTS classique échouerait par manque de temps et trop de branches à visiter, le nôtre va à chaque fois retourner un coup utile. Tout cela en fait un réel adversaire, imparfait évidemment, mais suffisamment intelligent pour offrir au joueur une partie vraiment intéressante.

3.5 Pipeline d'apprentissage automatique

Nous avons ajouté une politique de sélection ML pour le MCTS. L'objectif n'est pas de remplacer tout le moteur de recherche, mais uniquement la sélection du prochain enfant à explorer.

La figure 6 résume le pipeline complet : génération de parties en self-play, extraction des features, entraînement du modèle, puis intégration dans le MCTS.




FIGURE 6 – Pipeline ML : génération, entraînement et intégration en jeu

Dataset. Le dataset est construit à partir de 504 parties jouées en self-play entre plusieurs variantes de nos IA : Minimax à profondeurs 1, 2 et 3 avec les trois heuristiques, et Iterative Deepening avec trois budgets de temps distincts. Chaque partie est rejouée tour par tour pour extraire un vecteur de 20 features par coup. On obtient 34 365 exemples au format tabulaire.

Les 20 features sont réparties en trois groupes : contexte avant le coup, description du coup et effet du coup. La figure 7 résume cette décomposition.




FIGURE 7 – Les 20 features utilisées pour la sélection ML

Entraînement. Les données sont séparées en 80 % apprentissage et 20 % test avec stratification. Nous avons comparé quatre modèles classiques de scikit-learn. Les résultats sont donnés dans le tableau 2.

Modèle	Train Acc	Test Acc	F1	AUC
Régression Logistique	0,757	0,755	0,759	0,833
Arbre de Décision ($d=5$)	0,840	0,836	0,842	0,931
Random Forest (100)	1,000	0,938	0,939	0,987
Gradient Boosting	0,869	0,866	0,867	0,946

TABLE 2 – Comparaison des modèles ML

Le Random Forest est le meilleur compromis sur nos données : AUC de 0,987, F1 de 0,939 et intégration simple dans le moteur. Nous avons aussi testé un MLP Keras. Le MLP atteint une AUC de 0,975, inférieure au Random Forest. Nous avons donc retenu le Random Forest, plus précis et plus léger à intégrer.

Intégration dans le MCTS. La sélection ML remplace uniquement la formule UCT. Pour chaque enfant d'un nœud, le programme reconstruit les 20 features à partir de l'état avant le coup, du coup lui-même et de l'état après le coup. Le modèle calcule ensuite une probabilité de victoire, et l'enfant retenu est celui dont cette probabilité est maximale. Les autres étapes du MCTS restent inchangées : expansion, rollout et rétro-propagation.

Le mode est activé via `-ai-mcts-selection ML`. Le modèle est chargé une seule fois puis mis en cache. Le pseudo-code est donné en figure 10. Il représente uniquement l'étape de sélection : pour chaque enfant déjà généré, on calcule un score ML, puis on choisit celui qui obtient la meilleure probabilité de victoire.

Layer (type)	Output Shape	Param #
dense	(None, 128)	2,688
batch_normalization	(None, 128)	512
dropout	(None, 128)	0
dense_1	(None, 64)	8,256
batch_normalization_1	(None, 64)	256
dropout_1	(None, 64)	0
dense_2	(None, 32)	2,080
batch_normalization_2	(None, 32)	128
dropout_2	(None, 32)	0
dense_3	(None, 1)	33

Figure 8 – Architecture du MLP utilisé pour comparaison




Figure 9 – Comparaison Random Forest / MLP sur le jeu de test

```

fonction ml_select_child(noeud_parent):
    pour chaque enfant du noeud:
        construire ses features
        estimer sa probabilité de victoire avec le modele

    retourner l'enfant avec le meilleur score

```

FIGURE 10 – Pseudo-code de la sélection ML dans le MCTS

Conclusion

Suspendisse sit amet nisi placerat, vestibulum nisl vel, iaculis nunc. Suspendisse quis libero vel ipsum gravida congue nec id arcu. Donec vel mi viverra, commodo urna vitae, tincidunt lectus. Fusce pellentesque, lectus a placerat vestibulum, magna lectus placerat nibh, vehicula pellentesque lacus erat non nulla. Suspendisse maximus, turpis at suscipit egestas, libero massa ultrices libero, at tincidunt velit eros a eros. Maecenas id tempor nunc. Phasellus condimentum porttitor sapien in sagittis. Proin in metus diam. Mauris in turpis sed ex viverra iaculis. Sed lobortis, tellus vitae congue blandit, leo elit auctor libero, id tempor ante dolor quis quam. Donec eget ligula quam. Maecenas porttitor massa vel felis elementum tristique.

A Liste des 40 besoins

Cette annexe synthétise l'état de conformité des besoins fonctionnels. Les verdicts utilisés sont limités à **FAIT**, **PARTIEL** et **NON FAIT**. Lorsque l'exigence n'a pas encore fait l'objet d'un audit stabilisé, l'évaluation reste prudente et devra être confirmée lors de la relecture finale.

Exigence	Intitulé court	Verdict	Justification concise	Preuve / référence
F1	Exigence F1 à confirmer	PARTIEL	Évaluation à confirmer lors de la relecture finale ; audit détaillé non stabilisé à ce stade.	À revalider
F2	Exigence F2 à confirmer	PARTIEL	Évaluation à confirmer lors de la relecture finale ; audit détaillé non stabilisé à ce stade.	À revalider
F3	Exigence F3 à confirmer	PARTIEL	Évaluation à confirmer lors de la relecture finale ; audit détaillé non stabilisé à ce stade.	À revalider
F4	Exigence F4 à confirmer	PARTIEL	Évaluation à confirmer lors de la relecture finale ; audit détaillé non stabilisé à ce stade.	À revalider
F5	Exigence F5 à confirmer	PARTIEL	Évaluation à confirmer lors de la relecture finale ; audit détaillé non stabilisé à ce stade.	À revalider
F6	Exigence F6 à confirmer	PARTIEL	Évaluation à confirmer lors de la relecture finale ; audit détaillé non stabilisé à ce stade.	À revalider
F7	Annulation et rétablissement	PARTIEL	Le mécanisme existe, mais la conformité finale à la spécification doit être reconfirmée avant rendu.	Tests undo/redo à revalider
F8	Exigence F8 à confirmer	PARTIEL	Évaluation à confirmer lors de la relecture finale ; audit détaillé non stabilisé à ce stade.	À revalider
F9	Exigence F9 à confirmer	PARTIEL	Évaluation à confirmer lors de la relecture finale ; audit détaillé non stabilisé à ce stade.	À revalider
F10	Exigence F10 à confirmer	PARTIEL	Évaluation à confirmer lors de la relecture finale ; audit détaillé non stabilisé à ce stade.	À revalider

Exigence	Intitulé court	Verdict	Justification concise	Preuve / référence
F11	Exigence F11 à confirmer	PARTIEL	Évaluation à confirmer lors de la relecture finale ; audit détaillé non stabilisé à ce stade.	À revalider
F12	Exigence F12 à confirmer	PARTIEL	Évaluation à confirmer lors de la relecture finale ; audit détaillé non stabilisé à ce stade.	À revalider
F13	Exigence F13 à confirmer	PARTIEL	Évaluation à confirmer lors de la relecture finale ; audit détaillé non stabilisé à ce stade.	À revalider
F14	Exigence F14 à confirmer	PARTIEL	Évaluation à confirmer lors de la relecture finale ; audit détaillé non stabilisé à ce stade.	À revalider
F15	Shell interactif	PARTIEL	Le shell interactif est largement implémenté, mais la conformité globale n'a pas encore été consolidée exigence par exigence.	CLI et tests shell à revalider
F16	Exigence F16 à confirmer	PARTIEL	Évaluation à confirmer lors de la relecture finale ; audit détaillé non stabilisé à ce stade.	À revalider
F17	Exigence F17 à confirmer	PARTIEL	Évaluation à confirmer lors de la relecture finale ; audit détaillé non stabilisé à ce stade.	À revalider
F18	Exigence F18 à confirmer	PARTIEL	Évaluation à confirmer lors de la relecture finale ; audit détaillé non stabilisé à ce stade.	À revalider
F19	Exigence F19 à confirmer	PARTIEL	Évaluation à confirmer lors de la relecture finale ; audit détaillé non stabilisé à ce stade.	À revalider
F20	Déplacement et saut du pion	PARTIEL	Les règles de déplacement et de saut semblent présentes, mais la relecture finale de conformité reste nécessaire.	Règles du pion et tests à revalider
F21	Sauvegarde et restauration	FAIT	La sauvegarde et la restauration sont conformes, avec sections ordonnées, parseur robuste et messages d'erreur explicites.	Service de persistance ; tests save/load
F22	Commentaires dans la sauvegarde	FAIT	Les commentaires en ligne et en bloc sont correctement ignorés lors du parsing.	Parseur de sauvegarde ; tests CLI I/O
F23	Format des paramètres du jeu	FAIT	La section <code>[settings]</code> sérialise désormais les paramètres de partie et les principaux paramètres de programme au format clé-valeur.	Persistance ; tests program settings
F24	Format du plateau AS-CII	FAIT	Le format <code>[game]</code> est lu et écrit correctement, et les erreurs de lecture signalent maintenant le type d'erreur et la ligne concernée.	Contest parser ; tests contest
F25	Format de l'historique	FAIT	L'historique est écrit et relu sous forme de tours, puis rejoué pour reconstruire l'état de la partie.	Persistance ; tests history
F26	Module graphe générique	FAIT	Le projet fournit un module de graphe générique en liste d'adjacences, indépendant de Quoridor et réutilisable dans d'autres contextes.	<code>utils/graph.py</code> ; tests graphe
F27	Algorithmes sur les graphes	FAIT	Les algorithmes de validation, génération de coups, application, score et fin de partie sont bien intégrés au moteur.	Règles, session de jeu, tests
F28	Menus de la GUI	PARTIEL	Les menus et actions principales existent, mais la conformité textuelle à la spécification n'a pas encore été entièrement normalisée.	GUI ; tests menus à revalider
F29	Exigence GUI à confirmer	PARTIEL	Évaluation à confirmer lors de la relecture finale ; audit détaillé non stabilisé à ce stade.	À revalider
F30	Glisser-déposer du pion	FAIT	Le déplacement du pion à la souris par glisser-déposer est implémenté et testé.	GUI drag and drop ; tests GUI
F31	Temps de réflexion borné	FAIT	L'option <code>-ai-time</code> borne la réflexion et l'IA joue le meilleur coup complet trouvé avant expiration.	Minimax itératif ; tests IA
F32	Minimax avec élagage alpha-bêta	FAIT	L'algorithme minimax avec <i>alpha-beta pruning</i> est implémenté et activé par défaut pour le mode IA.	Moteur minimax ; config et CLI

Exigence	Intitulé court	Verdict	Justification concise	Preuve / référence
F33	Fonctions d'évaluation Minimax	FAIT	Trois fonctions d'évaluation sont disponibles et le scoring choisi est désormais propagé jusqu'au moteur minimax.	AI logic ; tests scoring
F34	Approfondissement itératif	FAIT	Le mode iterative réalise un approfondissement progressif de minimax en fonction du temps disponible.	Moteur itératif; tests dédiés
F35	Profondeur de recherche Minimax	FAIT	La profondeur maximale peut être fixée explicitement ou déterminée automatiquement à partir du temps disponible.	CLI, session, tests profondeur
F36	Monte Carlo Tree Search	FAIT	Le mode mcts est implémenté et utilise UCT comme politique de sélection standard par défaut.	Moteur MCTS; tests MCTS
F37	Sélection MCTS par apprentissage	FAIT	Une politique de sélection ML entraînée sur des parties jouées est disponible via -ai-mcts-selection ML.	Module ML, dataset, tests selector
F38	Exigence IA à confirmer	PARTIEL	Évaluation à confirmer lors de la relecture finale ; audit détaillé non stabilisé à ce stade.	À revalider
F39	Exigence IA à confirmer	PARTIEL	Évaluation à confirmer lors de la relecture finale ; audit détaillé non stabilisé à ce stade.	À revalider
F40	Exigence F40 à confirmer	PARTIEL	Évaluation à confirmer lors de la relecture finale ; audit détaillé non stabilisé à ce stade.	À revalider